

GERAÇÃO DE DADOS SINTÉTICOS DE QUALIDADE

MAPA DA AULA

Vamos acompanhar o mesmo caminho do notebook, mas em versão enxuta:

Passo 0: fixar semente e garantir reprodutibilidade.

Passos 1, 2A e 2B: entender o caso, identificar lacunas e propor hipóteses.

Passos 3 e 4: decidir a unidade de análise e o schema da base.

Passos 5, 6, 7 e 8: escolher distribuições, gerar sessões e inserir outliers plausíveis.

A meta não é sofisticação. A meta é produzir uma base sintética simples e justificável.

ENTENDIMENTO DO PROBLEMA

O CASO IPT

O IPT quer tomar decisões sobre comportamento de navegação na intranet. O problema é que os dados disponíveis são agregados e não mostram diretamente o comportamento de cada visita.

A aula mostra como sair desse ponto e montar uma base sintética mínima, coerente com o caso e fácil de explicar.

O QUE O PARCEIRO QUER

- Reduzir o tempo gasto procurando links operacionais
- Aumentar o engajamento com comunicados internos
- Segmentar usuários por perfil de comportamento
- Sustentar decisões de redesign e testes A/B

O QUE SABEMOS DO CASO?

QUAIS SINAIS JÁ APARECEM

MESMO COM DADOS AGREGADOS?

Para manter a aula simples

**vamos trabalhar um único
objetivo de negócio**

RECORTE DA AULA

Nesta aula, vamos focar em:

aumentar o engajamento com comunicados internos

Esse recorte reduz a complexidade, mas preserva o raciocínio central de geração de dados sintéticos.

O QUE A PLANILHA CONTÉM

Aba	O que contém	Granularidade
Tráfego geral	Visualizadores e visitas por dia	1 linha = 1 dia
Conteúdo popular	Itens mais visitados nos últimos 7 dias	1 linha = 1 item
Uso por dispositivo	Desktop, mobile app, mobile web, tablet	1 linha = 1 dia
Uso por tempo	Média de viewers por dia e hora	1 linha = 1 janela

O QUE JÁ CONSEGUIMOS AFIRMAR

- O acesso é majoritariamente desktop
- Há janelas claras de pico entre 8h e 11h
- Alguns conteúdos concentram grande parte das visitas
- O dado é agregado, não comportamental por sessão

O QUE FALTA NOS DADOS?

ONDE ESTÃO AS LACUNAS

QUE IMPEDEM ANÁLISE COMPOR-
TAMENTAL DIRETA?

LACUNAS PRINCIPAIS

- Não há sessão individual
- Não há perfil de usuário observável
- Não há sequência de navegação até o comunicado
- Não há sinal claro do que aconteceu depois da leitura

COMO VIRAR LACUNA EM
HIPÓTESE?

SE O DADO NÃO EXISTE,

O QUE PODEMOS ASSUMIR COM
CRITÉRIO?

DA LACUNA À HIPÓTESE

Lacuna: não sabemos quem lê comunicados, nem como a leitura se distribui ao longo das sessões.

Hipótese simples: em dias úteis, a maior parte das sessões de leitura ocorre em desktop, entre 8h e 11h, com alguns perfis lendo mais do que outros.

O QUE CADA LINHA DA BASE
REPRESENTA?

USUÁRIO, SESSÃO, PÁGINA
OU CLIQUE?

Decisão de modelagem

1 linha = 1 sessão

MODELAGEM DA BASE

QUAIS COLUNAS A BASE TERÁ?

ANTES DE GERAR,

PRECISAMOS NOMEAR AS VAR-
IÁVEIS.

COLUNA MINIMO DA BASE

```
1  colunas = [  
2      "session_id",  
3      "perfil_usuario",  
4      "tipo_dispositivo",  
5      "dia_semana",  
6      "faixa_horaria",  
7      "origem_acesso",  
8      "objetivo_sessao",  
9      "pageviews",  
10     "tempo_busca_segundos",  
11     "tempo_leitura_segundos",  
12     "tempo_total_segundos",  
13     "usou_busca",  
14     "clicou_comunicado",  
15     "sucesso_encontrou_o_que_queria",  
16     "busca_realizada" ]
```


QUAL DISTRIBUICAO USAR?

A FORMA ESTATISTICA DEPENDE
DO TIPO DE COMPORTAMENTO
MODELADO.

BERNOULLI

Use Bernoulli quando a variavel so pode assumir dois valores.


Exemplo trivial: `clicou_comunicado` = 1 OU 0.



LOG-NORMAL

Use log-normal quando a variavel e sempre positiva e assimetrica.


Exemplo trivial: `tempo_leitura_segundos`.



POISSON

Use Poisson quando a variavel representa contagens em um intervalo.

Exemplo trivial: `pageviews` na sessao.



```
1 def escolher_objetivo(perfil):
2     if perfil == "pesquisador":
3         return sorteio({
4             "ler_comunicado": 0.45,
5             "buscar_documento": 0.35,
6             "buscar_sistema": 0.20,
7         })
8     return sorteio({
9         "ler_comunicado": 0.25,
10        "buscar_documento": 0.25,
11        "buscar_sistema": 0.50,
12    })
13
14 def prob_clicar_comunicado(objetivo, faixa_horaria):
15     p = 0.12
16     if objetivo == "ler_comunicado":
17         p += 0.58
```


GERANDO UMA SESSÃO

```
1 for session_id in range(n):
2     perfil = escolher_perfil()
3     dispositivo = escolher_dispositivo()
4     dia = escolher_dia_semana()
5     faixa = escolher_faixa_horaria()
6     objetivo = escolher_objetivo(perfil)
7
8     pageviews = np.random.poisson(lam_por_objetivo[objetivo])
9     tempo_busca = np.random.lognormal(*param_busca[objetivo])
10    tempo_leitura = np.random.lognormal(*param_leitura[objetivo])
11    clicou = bernoulli(prob_clicar_comunicado(objetivo, faixa))
12
13    linha = montar_sessao(
14        session_id, perfil, dispositivo, dia, faixa,
15        objetivo, pageviews, tempo_busca, tempo_leitura, clicou
```

REALISMO E FECHAMENTO

INSERINDO OUTLIERS

```
1 idx_tempo = df.sample(frac=0.006, random_state=42).index
2 df.loc[idx_tempo, "tempo_leitura_segundos"] *= np.random.uniform(2.2,
    4.0, len(idx_tempo))
3
4 idx_pv = df.sample(frac=0.004, random_state=7).index
5 df.loc[idx_pv, "pageviews"] += np.random.randint(8, 18, len(idx_pv))
6
7 df["abandono_rapido"] = (
8     (df["tempo_total_segundos"] < 35) &
9     (df["pageviews"] <= 2)
10 ).astype(int)
```

O QUE LEVAR DESTA AULA

- Fixar semente ajuda a reproduzir o experimento
- Lacuna e hipótese não são a mesma coisa
- Unidade de análise define o que a base consegue mostrar
- Dado sintético bom e dado simples, explicável e justificável

AVALIAÇÃO DO ENCONTRO



ADALOVE

