

AVALIAÇÃO DOS DADOS SINTÉTICOS



COMBINADOS

👍 MODELO DE AULAS

👍 CHECK-IN

- Só faça check-in se estiver na sala de aula. Atrasos e a não permanência implicam em falta

👍 FEEDBACK

- Lembre-se de deixar um feedback de como foi o encontro. Avise se o sarrafo estiver baixo ou alto demais

👍 PRAZOS

- A regra geral é que as atividades devem ser entregues no prazo. Com boas justificativas (e com a concordância do orientador) podemos estender o prazo em algumas circunstâncias
- Trabalhos entregues com atraso (2 dias) terão um desconto de 30% da nota. Após, 50% de desconto.
- Cada um tem uma ficha de atividade ponderada para atrasar 2 dias sem descontos
- Foco




ALVOS

Neste encontro, você deverá:

1. Gerar e Avaliar a qualidade dos dados sintéticos.



MAPA DA JORNADA DE PROGRAMAÇÃO



ESTUDANDO OS DADOS DO PROJETO!

DADOS BRUTOS

Dados do ChartBeat

referrer	total_stories	avg_engaged_min	page_views	quality_page_views	uniques
Google Discover	70.002	00:43	95560	95560	85.124
Outbrain	11.198	01:03	10625	10625	6.769
Google Search	9.875	00:34	16962	16962	11.687
Facebook	2.351	00:14	9728	9728	8.015

Número de usuário para o referrer

DERIVANDO COLUNAS: PV_POR_USER

Dados do ChartBeat

referrer	uniques	page_views	pv_por_user
Google Discover	85.124	95560	1.12
Outbrain	6.769	10625	1.57
Google Search	11.687	16962	1.45
Facebook	8.015	9728	1.21

$\text{page_views} / \text{uniques}$

DERIVANDO COLUNAS: ENGAJAMENTO_MÉDIO

Dados do ChartBeat

referrer	uniques	page_views	pv_por_usuario	eng_médio_por_ref
Google Discover	85.124	95560	1.12	0.82
Outbrain	6.769	10625	1.57	1.65
Google Search	11.687	16962	1.45	0.85
Facebook	8.015	9728	1.21	0.29

$\text{total_engaged_min} / \text{uniques}$

DERIVANDO COLUNAS: RAZÃO DA QUALIDADE

Dados do ChartBeat

referrer	uniques	page_views	pv_por_user	eng_médio_por_re	quality_ratio
Google Discover	85.124	95560	1.12	0.82	0.63
Outbrain	6.769	10625	1.57	1.65	0.72
Google Search	11.687	16962	1.45	0.85	0.58
Facebook	8.015	9728	1.21	0.29	0.22


quality_page_views / page_views

QUAIS **DISTRIBUIÇÕES** CADA
VARIÁVEL DEVE UTILIZAR?

DISTRIBUIÇÃO DE POISSON

Utilizar quando as variáveis:

1. Ocorrem em um intervalo fixo (tempo, espaço, sessão)
2. São independentes entre si
3. Têm uma taxa média constante (λ)



PAGEVIEW → DISTRIBUIÇÃO DE POISSON

Característica

Se aplica a `pageviews` por usuário?

Evento discreto (número inteiro)

☒ Sim. São páginas inteiras (1, 2, 3...)

Ocorre por unidade de tempo/sessão

☒ Sim. Cada linha representa um usuário/sessão

Média conhecida, dispersão baixa

☒ Temos a média (1.12), e valores altos são raros


Independência dos eventos

☒ Assume-se que o comportamento de um usuário não afeta outro

DISTRIBUIÇÃO LOG-NORMAL

Utilizar quando as variáveis:

1. Dados assimétricos positivos (cauda longa à direita).
2. Fenômenos multiplicativos (produto de variáveis aleatórias).
3. Variáveis estritamente positivas (sem limite superior claro).




ENGAGED_TIME → DISTRIBUIÇÃO LOG-NORMAL

Característica	A log-normal consegue modelar?
Não pode ser negativo	☒ Sempre positiva
Muitas pessoas com pouco tempo	☒ Acúmulo no lado esquerdo
Poucos casos com tempo muito alto	☒ Cauda longa à direita
Média $\neq$ Mediana (assimétrica)	☒ Sim

DISTRIBUIÇÃO BINOMIAL

Utilizar quando:

1. Número fixo de tentativas (n)
2. Apenas dois resultados (sucesso/fracasso)
3. Probabilidade constante



QUALITY_PAGEVIEWS → DISTRIBUIÇÃO BINOMIAL

Elemento do problema	Interpretação em termos de Binomial
Cada pageview	É uma tentativa
Ser uma pageview de qualidade	É um sucesso
Proporção agregada de qualidade (ex: 63%)	É a probabilidade de sucesso (p)
Número total de páginas vistas pelo usuário	É o número de tentativas (n)
Número de quality_pageviews	É o número de sucessos (x)

SIMULAÇÃO DAS DISTRIBUIÇÕES

```
# pageviews: 95.560 / 85.124  $\approx$  1,12
```

```
pageviews = np.random.poisson(1.12, size=85124)
```

```
# engaged_time: 70.002 / 85.124  $\approx$  0,82 min (49 segundos)
```

```
engaged_time = np.random.lognormal(mean=np.log(0.82), sigma=0.6, size=85124)
```

```
# quality_pageviews: 60.423 / 95.560  $\approx$  0.63
```

```
quality_pageviews = np.random.binomial(n=pageviews[i], p=0.63)
```

COMO AVALIAR A QUALIDADE
DESSA **DISTRIBUIÇÃO?**

AVALIAÇÃO DA QUALIDADE DA DISTRIBUIÇÃO

```
pv_mean = pageviews.mean()
eng_mean = engaged_time.mean()
qlt_prop = quality_pageviews.sum() / pageviews.sum()

print("Média de pageviews:", pv_mean) # Deve ser ≈ 1.12
print("Média de tempo engajado:", eng_mean) # Deve ser ≈ 0.82
print("Proporção de quality pageviews:", qlt_prop) # Deve ser ≈ 0.63
```

GERAÇÃO E AVALIAÇÃO DE DADOS SINTÉTICOS

Acesse o notebook a seguir para visualizar.

https://colab.research.google.com/drive/1R-DV6F5bMIG7PFV2wXfdN_7P72-Q33hR?usp=sharing

COMPARAÇÃO FINAL

	métrica	esperado	simulado	diferença (%)	
0	pageviews_total	95560.000000	95560.000000	0.000000	✓ Perfeito
1	pageviews_media	1.122598	1.122598	0.000000	✓ Perfeito
2	engaged_min_total	70002.000000	70026.256118	0.034651	✓ Dif. Irrelevante
3	engaged_min_media	0.822353	0.822638	0.034651	✓ Dif. Irrelevante
4	quality_total	60423.000000	60494.000000	0.117505	✓ Dif. Irrelevante
5	quality_proporcao	0.632304	0.633047	0.117505	✓ Dif. Irrelevante

**UMA DISTRIBUIÇÃO SÓ É APROPRIADA SE
SUAS HIPÓTESES FOREM COMPATÍVEIS
COM A REALIDADE DA VARIÁVEL**

VOCÊ SE SENTE MAIS CONFIANÇA
NOS DADOS SINTÉTICOS COM
ESSAS **ÂNCORAS ESTATÍSTICAS?**

FAÇA VOCÊ AGORA!

1. Baixe um dataset do ChartBeat
2. Escolha 3 variáveis
3. Crie dados sintéticos para essas variáveis
4. Construa uma tabela de comparação para verificar as diferenças

AVALIAÇÃO DO ENCONTRO



ADALOVE



BACKUP